Projet *modélisation de bases de données*

Le projet du cours *Modélisation de bases de données* consiste à simuler une situation où vous devrez prendre des données, les **comprendre**, **modéliser**, **normaliser**, insérer dans un SGDB et les optimiser afin de permettre aux utilisateurs finaux d'accéder aux informations pertinentes.

Quelques points importants sont à noter :

1. Ce travail est à réaliser en binôme (max 3 personnes), vous devrez donc rendre un compte-rendu (ainsi que le matériel que vous jugerez pertinent) pour le binôme. Pensez à mettre les noms dans tous les éléments que vous déposerez.
2. Ce travail n'a pas de solution unique, c'est à vous de proposer des solutions pour insérer les données, les normaliser et les optimiser. Il vous faudra indiquer clairement les choix que vous avez fait et les argumenter.
3. Il vous faut garder en mémoire que l'objectif final consiste à proposer un outil qui doit permettre de gérer de manière la plus efficace possible des données (les visualiser, les modifier, calculer des statistiques, …).
4. Vous aurez besoin de vos connaissances en logique, Linux, programmation, etc. (courage 😉).

Pour ce projet (qui durera jusqu'au **03/03/2025 23h59**), vous allez travailler sur des données issues des archives départementales de Vendée, données utilisées par des généalogistes et des démographes. Ces données sont fournies en un fichier au format CSV avec l'intitulé des colonnes suivant :

`mariages_L3_5k.csv:`

1. **Identifiant d'acte**
2. **Type d'acte**
3. **Nom personne A**
4. **Prénom personne A**
5. **Prénom père personne A**
6. **Nom mère personne A**
7. **Prénom mère personne A**
8. **Nom personne B**
9. **Prénom personne B**
10. **Prénom père personne B**
11. **Nom mère personne B**
12. **Prénom mère personne B**
13. **Commune**
14. **Département**
15. **Date**
16. **Num Vue**

Les généalogistes veulent un système pour consulter les mariages disponibles dans ses registres et éventuellement avoir la capacité d'ajouter des nouveaux registres. Ce système doit avoir les caractéristiques suivantes :

1. Chaque personne doit avoir un identifiant unique

2. Ils existent les types d'acte suivantes :
    a. Certificat de mariage
    b. Contrat de mariage
    c. Divorce
    d. Mariage
    e. Promesse de mariage - fiançailles
    f. Publication de mariage
    g. Rectification de mariage
3. Les seules départements valides sont :
    a. 44
    b. 49
    c. 79
    d. 85
4. Un département peut contenir plusieurs communes mais une commune appartient seulement à un département

L'information demandée par les généalogistes est la suivante :

1. La quantité de communes par département
2. La quantité de actes à LUÇON
3. La quantité de "contrats de mariage" avant 1855
4. La commune avec la plus quantité de "publications de mariage"
5. La date du premier acte et le dernier acte

Étapes :

1. Conceptualiser et modéliser les tables et attributs avec les clés nécessaires.
2. Normaliser votre schéma relationnel.
3. Créer un compte sur https://www.dbdesigner.net/ . Cet outil vous permettra de visualiser votre base de données, et si c'est le cas, améliorer votre modélisation.
4. Exporter votre modélisation à SQL (PostgreSQL). Attention ! Il faudra effacer le texte `public.` des noms des tables, ex. :

    `public.commune -> coummune`

5. Créer votre base de données sur PostgreSQL. Vous pouvez consulter le lien suivant : https://www.convert-in.com/import-postgresql-script.htm .
6. Extraire les données des colonnes différentes à partir du fichier .csv pour les insérer dans les tables crées. Il faudra être créatif.ve dans cette étape (expressions réguliers, commandes linux, programmer, etc.). Vous pouvez utiliser un éditeur de texte comme "Sublime Text" avec des expressions régulières mais les commandes linux sont les plus efficaces, ex. :

    ```
    cut -f2 -d"," mariages_L3_5k.csv |sort|uniq > type_acte.csv
    ```

    Cette suite de commandes extraient d'abord la deuxième colonne du fichier `mariages_L3_5k.csv` à partir du séparateur `","` , puis elle trie par ordre alphabétique, en suite elle filtre les lignes adjacentes pour les fusionner sur la première occurrence. Finalement elle redirectionne la sortie vers le nouveau fichier `type_acte.csv` . Des autres commandes utiles sont : `grep` `cat` `sed` `more`. À vous de chercher la documentation:)

7. Insérer dans votre base de données le contenu des fichiers extraits. Vous pouvez consulter les liens suivants :
    a. https://docs.postgresql.fr/14/sql-copy.html
    b. https://www.postgresqltutorial.com/postgresql-tutorial/import-csv-file-into-posgresql-table/

    *Si vous obtenez une erreur similaire à :

    ```
    ERROR:  could not open file "./type_acte.csv" for reading: Aucun fichier ou dossier de ce type
    ```

    ```
    HINT:  COPY FROM instructs the PostgreSQL server process to read a file. You may want a client-side facility such as psql's \copy.
    ```

    , changez `COPY` pour `\copy` , ex. :

    ```
    \copy  type_acte(type) FROM './type_acte.csv' DELIMITER ',' CSV;
    ```

    pour une table `type_acte` avec l'attribut `type (varchar)`.

8. Créer vos requêtes pour répondre aux questions des généalogistes.

Rendue :

1. Le fichier résultant de la modélisation pour créer la base de données
2. Tous les scripts que vous avez créés
3. Un fichier `pdf` avec :
    a. prénoms et noms du binôme ou du groupe
    b. votre modèle relationnel (sortie du dbdesigner)
    c. vos requêtes et ses résultats

BONUS : `mariages_L3_5k.csv` contient des données propres, avec des colonnes bien définies. Travaillez maintenant avec le fichier `mariages.csv` . Si la modélisation de la base de données a été bien fait, rien à changer, le challenge est de traiter ce fichier bruité avec environ 564k registres et répondre aux mêmes questions qu'avant.

Rendue BONUS:

1. Tous les scripts que vous avez créés
2. Ajouter au `pdf` :
    d. une description avec les difficultés que vous avez trouvées et comment avez-vous réussi à les résoudre
    e. vos requêtes et ses résultats du bonus

Information utile :

- https://www.postgresqltutorial.com/postgresql-administration/
- https://www.w3schools.com/sql/

- https://stackoverflow.com/questions/25969/insert-into-values-select-from

Date de dépôt : **03 mars 2025 23h59** sur Moodle